11/26/23. 9:20 AM fecha

```
In [ ]: from pyspark.sql import SparkSession
        from pyspark.sql.functions import *
        from pyspark.sql.types import *
        spark = SparkSession \
             .builder \
            .appName("how to read csv file") \
             .getOrCreate()
```

Setting default log level to "WARN".

To adjust logging level use sc.setLogLevel(newLevel). For SparkR, use setLogLevel(newLevel).

2023-11-26T12:56:22,835 WARN [Thread-4] org.apache.hadoop.util.NativeCodeLoader - Unable to load native-hadoop librar y for your platform... using builtin-java classes where applicable

2023-11-26T12:56:24,589 WARN [Thread-4] org.apache.spark.util.Utils - Service 'SparkUI' could not bind on port 4040. Attempting port 4041.

2023-11-26T12:56:24,590 WARN [Thread-4] org.apache.spark.util.Utils - Service 'SparkUI' could not bind on port 4041. Attempting port 4042.

#### Cargo los datos en un dataframe de spark

```
In [ ]: fecha_refined = spark.read.csv('/user/ort/obligatorio/fecha.csv', header=True)
```

## Vista previa de las primeras filas

```
In [ ]: fecha_refined.show()
```

11/26/23, 9:20 AM fecha

```
id|fecha_alta|fecha_baja|
 1 6/2/2021
                     null|
 2 | 6/2/2021 |
                     null|
 3 | 6/3/2021 |
                     null|
 4 | 6/3/2021 | 3/13/2022
 5 | 6/4/2021 | 11/5/2023 |
 6 6/4/2021 7/3/2022
7 | 6/5/2021
                     null
 8 6/8/2021
                     null
 9 6/9/2021
                     null
10 | 6/11/2021 |
                     null
11 | 6/12/2021 |
                     null
12 | 6/12/2021 |
                     null|
13 | 6/13/2021 |
                     null
14 | 6/13/2021 |
                     null|
15 | 6/15/2021 |
                     null
16 | 6/15/2021 |
                     null
17 | 6/16/2021 |
                     null
18 | 6/16/2021 |
                     null
19 | 6/18/2021 |
                     null
20 6/19/2021
                     null|
```

only showing top 20 rows

### Cantidad de columnas del dataframe monthly\_pays

```
In [ ]: num_columns=len(fecha_refined.columns)
num_columns
```

Out[ ]: 3

# Nombre de las columnas de monthly\_pays

```
In [ ]: fecha_refined.columns
Out[ ]: ['id', 'fecha_alta', 'fecha_baja']
```

#### Descripción de los datos de la tabla

11/26/23, 9:20 AM fecha

```
In [ ]: fecha_refined.describe
Out[]: <bound method DataFrame.describe of DataFrame[id: string, fecha_alta: string, fecha_baja: string]>
        Schema de la tabla
In [ ]: fecha_refined.printSchema()
      root
        |-- id: string (nullable = true)
        |-- fecha_alta: string (nullable = true)
        |-- fecha_baja: string (nullable = true)
        Valores Nulos o Faltantes
In [ ]: total nulos = fecha refined.select([sum(col(c).isNull().cast("int")).alias(c) for c in fecha refined.columns])
        total nulos.show()
       +---+
       | id|fecha alta|fecha baja|
       +---+
       +---+
        Los valores nulos corresponden a los usuarios que no se han dado de baja, por lo cual se decide mantenerlos como nulos.
        spark = SparkSession.builder.appName("EjemploConversionFecha").getOrCreate()
        spark.conf.set("spark.sql.legacy.timeParserPolicy", "LEGACY")
      2023-11-26T12:56:38,308 WARN [Thread-4] org.apache.spark.sql.SparkSession - Using an existing Spark session; only run
      time SQL configurations will take effect.
In [ ]: fecha_refined = fecha_refined.withColumn("fecha_alta", to_date(col("fecha_alta"), "MM/dd/yyyy"))
    ]: fecha_refined = fecha_refined.withColumn("fecha_baja", to_date(col("fecha_baja"), "MM/dd/yyyy"))
```

11/26/23, 9:20 AM fecha